# 补充材料：选择后误差监测的开发实验与完整性审计

2026年9月17日

与论文阶段稿配套；独立验证结果尚未并入

## S1 信息可见性与数据隔离

优化器只读取截至上一轮的已付费标签。每次评价前保存并刷新所选点预测、上界、已知最优、目标尺度、模式和随机状态；标签返回后才更新历史与监测。图1给出优化与诊断两条路径。诊断不向优化器提供反馈，候选池标签不作为免费训练数据。

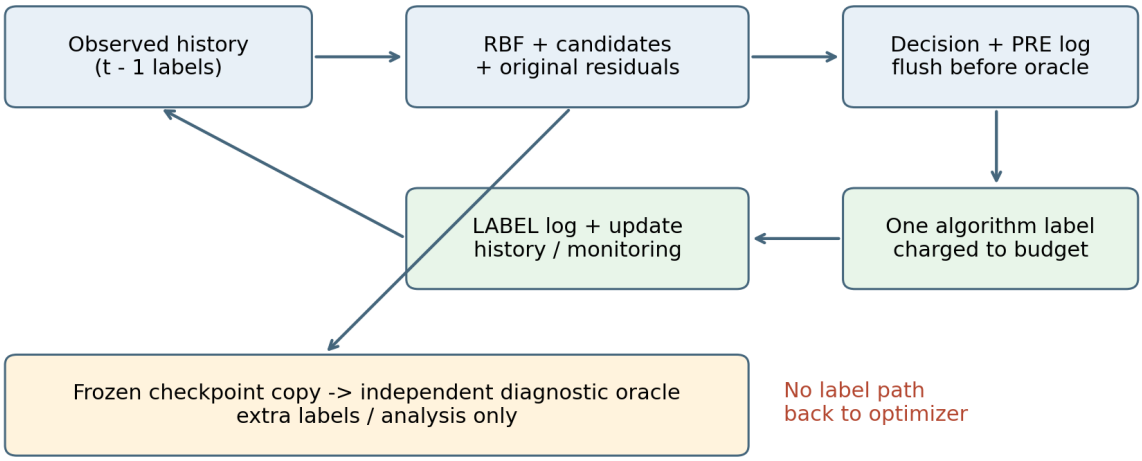



图 1: 算法与诊断的信息路径。PRE日志先于真实标签保存，离线诊断读取冻结状态。虚构廉价标签或事后重新计算训练残差均不属于本实验。

### S1.1 一轮执行的明确顺序

1. 读取历史，按预定规则截断训练子集；拟合RBF并保存训练索引与标签尺度。
2. 生成256候选，预测均值；从原预测残差计算G/T/S/ST上界与支持回退。
3. 读取已完成监测窗口与停滞次数，计算探索概率；仅由当前可见信息选择一个点。
4. 保存候选检查点及所选点PRE记录，刷新文件；随后调用目标函数一次。
5. 写LABEL记录，以原预测及原尺度构成残差；更新监测、停滞、历史。
6. 达到预算即停止；已知最优值仅在结束后的统计中读取。

启动阶段前D+10次训练、后D+10次在线预测评价，全部付费；不将训练残差充作监测残差。内部方法共享初始化，后续独立轨迹即使整数种子相同也不拥有同一候选池。

## S2 冻结实现参数

表 1: 开发v1参数（实现选择，不作为创新）

| 参数 | 数值 |
|---|---|
| kernel_scale | 0.25 |
| ridge | 1e-06 |
| max_train | 256.0 |
| elite_train | 128.0 |
| parents | 64.0 |
| candidates | 256.0 |
| F | 0.5 |
| CR | 0.9 |
| pbest | 0.2 |
| residual_window | 100.0 |
| half_life | 25.0 |
| spatial_k | 20.0 |
| min_support | 20.0 |
| monitor_window | 30.0 |
| level | 0.9 |
| duplicate_tol | 1e-10 |
| tau_factor | 1e-06 |

标签尺度使用当前所选训练子集的总体标准差，为零时置1。距离为归一化欧氏距离。分位数逆经验CDF不插值，负上侧分位数截为零。反馈窗口包括启动在线预测记录。并列按原索引，重复容差与越界反射规则固定；额外Sobol补齐不获取目标标签。

开发实验B=10D，D=10/20时预算100/200，完整初始化40/60。每轨迹检查点分别41/50/75/100和61/100/150/200；首个检查点经过初始化修正，不能称25%预算。诊断每状态256额外标签，所有校准器和策略复用同一组隐藏标签，不重复收集付费优化数据。

## S3 声明支持与错误数量

图2公开各方法声明总数和真假改善数量。声明不是概率保证，上界失效目标10%不意味着声明子集90%成功。零声明时FDP为NA，不能写成零错误率证明可靠。

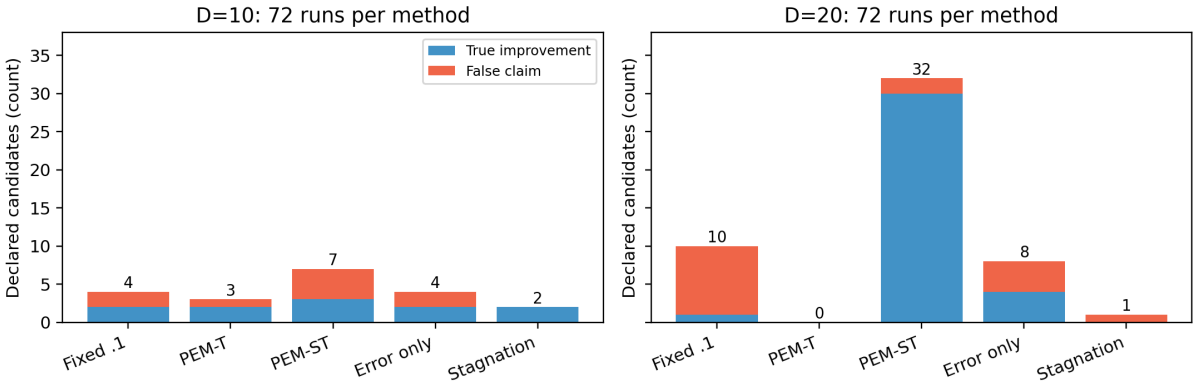



图 2: 开发闭环中的改善声明计数。每维每方法72运行；柱高是声明数，颜色表示实际改善与错误声明。PEM-T在20维没有声明，图中零柱不是可靠性优势。

只有原型的受监测声明使用当前原预测上界，数值阈值为当前尺度乘1e-6。所有假声明都经日志核查满足上界失效事件包含关系；该包含关系不控制FDP分母，也不保证每轮成功概率。

## S4 可追溯的单轨迹例子

事后展示f20、D=10、实例1、重复0。示例选择发生在开发结果汇总之后，未按单次最大差距挑选；它是描述性例子，不能估计典型性或替代正文8函数总体统计。两方法初始化与初始误差相同；最终PEM-T误差稍高，不能据一条轨迹判断机制普遍失效。

表 2: 固定展示轨迹，后初始化阶段60次评价

| 方法 | 终点误差 | 探索次数 | 上界失效次数 | 声明数 | 错误数 |
|---|---|---|---|---|---|
| fixed01 | 3.201643 | 6 | 2 | 0 | 0 |
| PEM_T | 3.514912 | 19 | 5 | 0 | 0 |

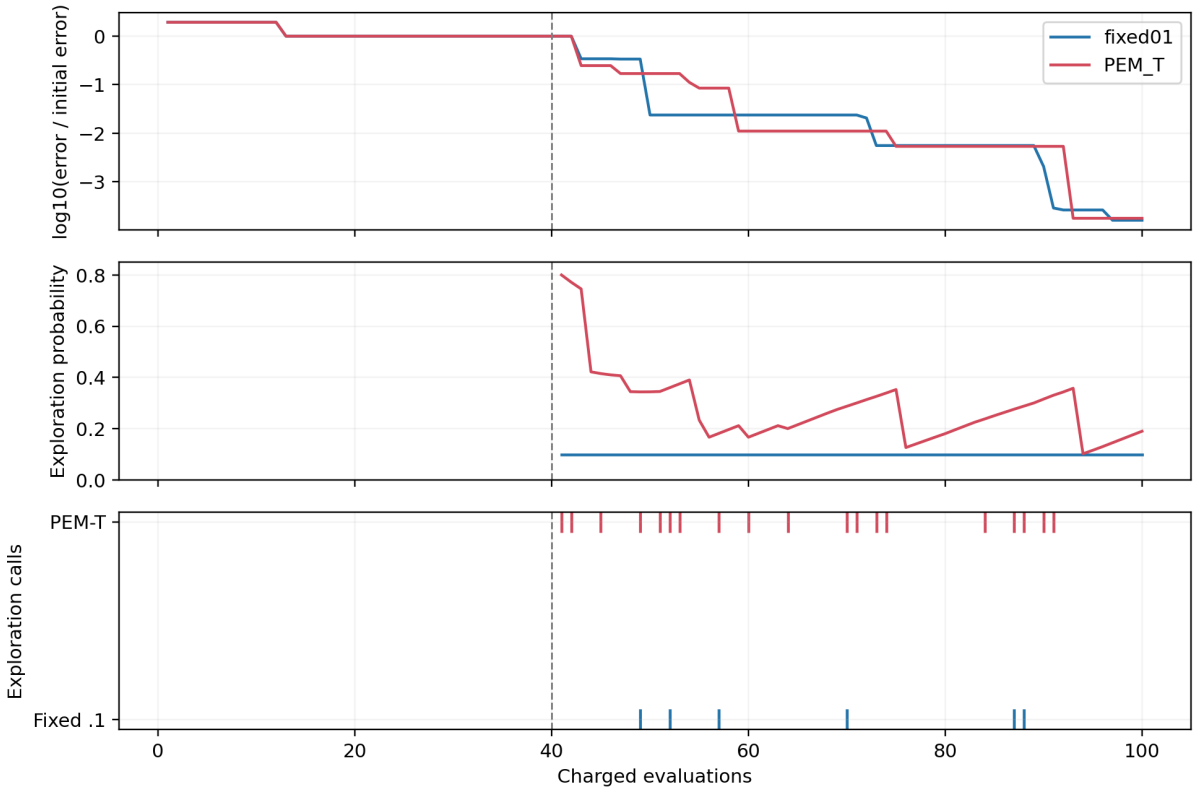



图 3: f20、10维、实例1、重复0的真实轨迹。上：当前最优误差；中：评价前探索概率；下：实际空间探索评价。虚线为初始化结束；后续差异来自独立闭环，不能解释为同池选点差异。

原始轨迹目录为`results/development_v1/PEM_T_f20_d10_i1_r0_b100`与对应fixed01目录。所展示数据保存于`results/supplement_v1/case.json`，图形由标签日志和PRE模式生成，没有平滑或删除评价。

## S5 完整性与阶段边界

开发1,872轨迹、280,800算法评价；共同历史432轨迹、64,800算法评价；其中288轨迹为保存完整候选池而重复执行，不增加统计样本。诊断1,728状态、442,368标签，与算法隔离。所有完成标记、预算计数、初始化配对及标签顺序已核查。两组144/144轨迹等价性支持当前实现的代数分析。

统计单位为函数，重复用于实例内中位数；正文采用8函数配对比较、20项Holm校正及配对分层重采样。开发集用于选定固定概率，不能将该比较写成独立确认。软件锁、硬件记录和原型指纹分别保存在docs下，异常环境安装记录保留。

本材料不包含正在运行的新机制验证标签。新阶段先冻结协议与统计脚本，采用全24函数、10/20/40维、实例11 – 13；结果应另行审计、单列，不与开发数据合并。原计划实例6 – 10仍未读取。外部竞争方法的完整性能复现、CEC和应用未完成。

作者代码预算审查的TuRBO控制流反例另存于`results/author_code_audit/`，不与BBOB优化结果混合。完整性检查不能替代算法有效性；开发门槛失败如实报告。